

浙 江 理 工 大 学

毕业设计(论文)诚信声明

本人郑重声明：我恪守学术道德，崇尚严谨学风。所呈交的毕业设计(论文)是本人在导师的指导下，独立进行研究工作所取得的成果。本人所写的毕业设计(论文)，凡引用他人的研究成果均已在参考文献或注释中列出。设计(论文)主体均由本人独立完成，没有抄袭、剽窃他人已经发表或未发表的研究成果行为。如出现以上违反知识产权的情况，本人愿意承担相应的责任。

学校有权保留本毕业设计(论文)，允许被查阅和借阅，可以将本毕业设计(论文)的内容编入有关数据库进行检索或向上级有关部门送交本毕业设计(论文)。

声明人(签名):

年 月 日

摘 要

海洋生物是海洋生态系统中重要的组成部分,对于维持海洋生态平衡和生物多样性具有重要意义。通过深度学习技术,可以实现对海洋生物的自动化识别和监测,从而更好地保护海洋生物资源,监测海洋生态环境的变化,提高对海洋生态系统的管理水平。深度学习技术在海洋生物检测领域的应用,可以加速海洋生物学的研究进程。通过对海洋生物的大规模数据进行分析和挖掘,可以深入了解海洋生物的分类、行为特征、分布规律等,推动相关学科的发展和进步。基于深度学习的海洋生物检测研究具有重要的科学意义和应用价值,有助于更好地理解 and 保护海洋生态环境,推动海洋资源的可持续利用和海洋科学的发展。

本文针对 YOLOv9 复杂度高、参数量大、应用部署环境要求高等问题,提出了使用 MobileNetV3 替换 YOLOv9 主干网络进行轻量化改进。然而,仅仅将 YOLOv9 的主干网络替换为 MobileNetV3,虽然显著降低了模型的复杂度和参数量,但也可能导致模型性能的下降。为了解决这个问题,我们进一步对 YOLOv9-MobileNetV3 模型进行了优化。这些优化措施包括替换注意力机制,调整网络结构等,旨在提高模型的检测精度和泛化能力。最后进行模型优化前后对比,与其他模型性能对比,以及模型在其他数据集上的表现。从而体现出本文模型的检测能力的优异。

关键词: YOLOv9; MobileNetV3; 海洋生物检测; 系统开发

Abstract

Marine life is an important component of the marine ecosystem and is of great significance for maintaining marine ecological balance and biodiversity. Through deep learning technology, automatic identification and monitoring of marine life can be achieved, thereby better protecting marine biological resources, monitoring changes in the marine ecological environment, and improving the management level of the marine ecosystem. The application of deep learning technology in the field of marine biological detection can accelerate the research process of marine biology. By analyzing and mining large-scale data of marine life, we can gain an in-depth understanding of the classification, behavioral characteristics, and distribution patterns of marine life, and promote the development and progress of related disciplines. Marine biological detection research based on deep learning has important scientific significance and application value, helps to better understand and protect the marine ecological environment, and promotes the sustainable utilization of marine resources and the development of marine science.

In view of the problems of Yolov9's high complexity, large number of parameters, and high application deployment environment requirements, this paper proposes to use MobileNetV3 to replace the Yolov9 backbone network for lightweight improvements. However, simply replacing the backbone network of Yolov9 with MobileNetV3 may significantly reduce the complexity and number of parameters of the model, but it may also lead to a decrease in model performance. In order to solve this problem, we further optimized the Yolov9-MobileNetV3 model. These optimization measures include replacing the attention mechanism, adjusting the network structure, etc., aiming to improve the detection accuracy and generalization ability of the model. Finally, compare the model before and after optimization, compare the performance with other models, and the performance of the model on other data sets. This reflects the excellent detection ability of this model.

Keywords: Yolov9; MobileNetV3; marine life detection; system develop

目 录

摘 要

Abstract

第 1 章 绪论	1
1.1 研究目的与意义	1
1.2 国内外研究现状	1
1.3 研究内容与论文结构	3
第 2 章 相关理论和技术介绍	5
2.1 卷积神经网络	5
2.2 目标检测	5
2.3 数据集	6
第 3 章 基于深度学习的海洋生物检测的设计和实现	7
3.1 YOLOv9 神经网络模型	7
3.2 轻量化改进: MobileNetV3 替换骨架网络	9
3.2.1 MobileNetV3 网络结构	9
3.2.2 YOLOv9-MobileNetV3 网络设计	10
3.3 MobileNetV3 优化: 注意机制替换	11
3.4 添加双端注意机制 (SE+CA)	12
第 4 章 基于深度学习的海洋生物检测的实验结果	15
4.1 评价指标	15
4.2 模型优化前后的结果对比	15
4.2.1 轻量化优化	15
4.2.2 性能优化	16
4.2.3 优化后训练数据分析	16
4.3 与其他目标检测模型性能对比	18
4.3.1 YOLOv8	18
4.3.2 SSD	19
4.3.3 Faster R-CNN	20
4.3.4 实验结果	21
4.4 在其他数据集性能表现	21
4.4.1 Aquarium	21
4.4.2 RUIE	22
4.4.3 实验结果	22
第 5 章 海洋生物检测系统的搭建	23
5.1 框架选择	23
5.2 功能模块设计	23
5.3 业务流程设计	24
5.4 模块展示	24
5.3.1 登录模块	24
5.3.2 注册模块	25
5.3.3 图片检测模块	26

5.3.4 视频检测模块	27
5.3.5 摄像头检测模块	28
第 6 章 总结与展望	30
6.1 总结	30
6.2 展望	30
参考文献	32
致 谢	35

第1章 绪论

1.1 研究目的与意义

中国作为一个地大物博的国家，不仅是世界上的陆地大国，也是一个在东方屹立的海洋大国^[1]。自改革开放以来，开发海洋资源和维护海洋权益对于我国的发展越来越显著，我国也日益重视保护海洋权益，加速海洋资源的开发。在十八大的报告中指出，把我国建设成为海洋强国作为国家战略目标，显示了该目标的重要性，维护海洋权益已经成为国家战略中的重要组成部分^[2]。随着我国海洋经济的蓬勃发展，海洋牧场计划已经正式起航。这一计划的核心在于构建现代化的海洋牧场，这是一种创新的海洋生物资源开发模式，不仅顺应了当前可持续发展的战略需求，也展示了我国在海洋资源管理方面的前瞻性和决心。通过这种模式，可以促进海洋经济的持续健康发展，并有助于稳步实施海洋强国战略^[3]。

当前，越来越多的学者正在积极探索并应用深度学习技术于海洋生物检测领域。这一转变不仅拓宽了海洋生物研究的视野，也为海洋生物保护和资源管理带来了新的可能性。这种利用深度学习技术解决海洋生物检测问题的信息化方法可以构建以智能化基础设施为核心的海洋信息系统，实现智慧海洋和智能水产的目标。通过应用人工智能、机器视觉和其他传感器技术，可以实时监测生态环境等方面的信息。这种方法结合深度学习的图像识别和检测、机器学习等技术，可以对鱼类的生活习性、摄食强度、环境适应情况和生态环境信息进行综合分析，充分利用养殖数据以提升工作效率和决策可靠性^[4]。因此，基于深度学习的海洋生物图像目标检测的研究变得尤为必要。

1.2 国内外研究现状

刘洋等人^[2]提出了一种双路径(DP)金字塔视觉变换(PVT)特征提取网络 DP-fishnet，DP-PVT 骨干网络由双路径特征提取机制构成。一方面，它采用视觉变换路径，专注于全局特征的捕获，这一路径能够显著增强水下图像前景与背景的区分度，从而优化图像的识别与分割。另一方面，DP-PVT 还集成了卷积神经网络路径，该路径专注于局部特征的提取，对于提高小目标检测的精度尤为关键，能够确保图像中的细微信息得以准确捕捉和处理。这两条路径相辅相成，共同为

DP-PVT 网络提供了全面而细致的特征提取能力。此外, 为了更有效地利用网络提取的特征信息, 他们还提出了在特征金字塔网络 (FPN) 中采用内容感知特征重组 (Carafe) 的解决方案。针对鱼类种群数量差距不平衡问题, 他们使用 seesaw loss 作为分类损失来解决该问题。最后实验结果表明, DP-FishNet 的 AP50 和 AP 分别为 95.2% 和 76.0%。和当前比较先进的两阶段检测算法相比较, 无论是计算量还是参数量都大幅度下降, 下降大约 40%。DP-FishNet 通过提升水下图像中提取全局和局部特征的能力, 从而增强了特征的重用性。DP-fishnet 可以用于探测实际和复杂水下环境中的鱼类目标。

Guoyan Yu 等^[3]人提出来基于 YOLOv7 的深度学习目标检测算法, 设计了一个新的水下生物检测网络, 被称为 UnderwaterYOLOv7 (U-YOLOv7)。这种模型在速度和精度方面都满足要求。首先, 建立了一个结合交叉转换和高效挤压激励模块的网络。该网络不仅减少了参数量, 还增强了信道信息的提取, 从而增强了网络的特征融合能力。其次, 在特征融合之前, 使用轻量级的 CARAFE (Content-Aware ReAssembly of FEatures) 算子获取更多的水下图像语义信息; 为了提高模型在水下识别中的抗干扰能力, 引入了三维注意机制。最后, 设计了一种基于混合卷积的解耦头, 提高了水下探测的收敛速度和精度。结果表明, 该网络准确率提高了 3.2%, 召回率提高了 2.3%, 平均精度提高了 2.8%, 运行速度高达 179 fps, 远远优于其他先进的网络。与 YOLOv7 网络相比, 具有更高的估计精度。

白欣莹^[4]通过改进 YOLOv5 目标检测算法, 研究并实现海洋生物目标检测系统。由于图像目标较小, 然后随着卷积层的不断加深, 特征特别容易丢失, 因此她在原本的 YOLOv5 结构中增加 4 倍下采样的过程, 在原有的三个 YOLO Head 分支基础上, 增加一个专门用于预测小目标的检测头。同时, 为了实现更准确的检测, 可以对浅层特征与高分辨率语义信息进行融合, 改进了算法自学习能力, 增强了小目标检测敏感度, 降低了模型漏检率, 提高模型对复杂场景的适应性和准确性。因为海底环境复杂多变, 前景目标与背景交织在一起常出现误检情况, 之后再在 YOLOv5 网络结构中加入三重注意力机制, 提高重点关注区域的注意力权重, 提高模型对具有鉴别力的局部特征提取能力, 抑制背景无用信息, 改善模型误检程度。通过对比实验和测试表明系统具有可用性和稳定性, 满足实际应用需求。

除此之外，这些强大的目标检测算法的发展，也对海洋生物的研究起到了推动作用。例如，Liu 等人^[5]利用 Fast RCNN 对水下鱼类物种进行了检测识别，精度和速度相比 RCNN 都取得了很大的提升；Han 等人^[6]结合 max-RGB 和灰度梯度对原数据图像增强，使用改进深度卷积神经网络实现对海参、海胆等生物的检测；Song 等人^[7]利用 MSRCR 图像增强算法以及 Mask RCNN，将两者相结合，在小样本水下数据集上实现了高于 90% 的平均精度（mAP），但算法速度低，实用性不高的；Fan 等人^[8]构建六个预测层形成新的多尺度特征对新的水下数据集 UWD 进行检测，精度提升却不太明显；Chen 等人^[9]针对水下小目标使用多个高分辨率和语义丰富的特征图组合形成 SWIPENet 网络结构，但总体精度值并不算很高；Zeng 等人^[10]添加对抗性遮挡网络（AON）与 Faster RCNN 互相对抗学习正确分类被拦截目标，使得水下检测模型更具鲁棒性；Fang 等人^[11]在多尺度特征融合加入 shortcut 结构对层之间进行直接连接形成 S-FPN 结构，减少特征信息损失，对海参达到高精度检测效果；Liu 等人^[12]在 Faster RCNN 主干网络中嵌入核自适应选择单元提高特征提取能力，只使用高分率特征图进行检测，减少了对小型密集海洋生物的漏检，但这不利于多尺度目标的检测；Hu 等人^[13]使用 YOLOv4 中拥有更多小目标信息的高分辨率进行检测，并用 dense_unit 替换主干网络中的 res_unit，实现对水下密集小颗粒的检测；Zhang 等人^[14]在 YOLOv4 中加入 AFFM 注意力机制进行特征融合，获得更加丰富的语义信息，提高了水下目标检测的准确性；Li 等人^[15]通过在多尺度特征图上增加角点回归提高小目标的召回率，并改进回归损失反应真实框和预测框的差距。虽然这些模型在特定的目标场景下都取得了一定的成功，但针对本数据集图像模糊，生物颜色与背景类似等情况，仍需要对检测器进一步改进。

1.3 研究内容与论文结构

第 1 章详细阐述了海洋生物检测的重要性，介绍研究目的与意义以及基于深度学习的海洋生物检测技术的研究现状。

第 2 章主要介绍相关基础理论和技术，如 CNN，目标检测以及本文模型训练使用的数据集 RUOD。

第 3 章详细介绍 Yolov9 使用 MobileNetV3 轻量化改进，以及轻量化后的优化方案。

第 4 章主要介绍模型优化前后对比, 与其他模型性能对比, 以及模型在其他数据集上的表现, 从而体现出本文模型的优异性能。

第 5 章介绍了将训练好的模型部署到 WEB 平台进行实际海洋生物检测的系统开发流程。

第 6 章对全文进行了总结, 展望海洋生物检测技术的未来发展,

第 2 章 相关理论和技术介绍

本章主要介绍卷积神经网络（CNN），目标检测以及本文训练模型使用的数据集 ROUD。CNN 是深度学习在图像处理中的重要应用，通过卷积和池化提取特征，再利用全连接层进行分类或其他任务；而目标检测则是计算机视觉中的核心任务，通过目标定位、分类、边界框回归和后处理等步骤实现在图像中识别和定位特定对象。这些技术推动了人工智能领域的发展和进步；RUOD 数据集是一个非常不错的水下目标检测数据集，它能有效地训练我们的模型。

2.1 卷积神经网络

深度学习和卷积神经网络之间存在着紧密的联系，CNN 是深度学习在图像处理领域的一种重要应用，同时深度学习为 CNN 的训练和优化提供了有效的方法和技术支持。两者共同推动了人工智能领域的发展和进步。

CNN 的核心思想是通过卷积和池化提取特征，再通过这些特征来进行分类、识别或其他任务。以下是 CNN 的一些概念和组成：

卷积层：通过使用多个卷积核，对输入数据进行卷积运算，从而提取出数据中的特征。每个卷积核都独立地执行卷积操作，最终生成一组包含不同特征信息的特征图，这些特征图随后将作为下一层的输入继续在网络中传递。

池化层：对特征图进行降采样，减少特征图的维度和参数量，同时保留重要的特征。常见的池化操作包括最大池化（Max Pooling）和平均池化（Average Pooling）。

激活函数：在卷积层之后通常会添加一个激活函数，用于引入非线性特性，增加网络的表达能力。常用的激活函数有 ReLU、Sigmoid、Tanh 等。

全连接层：在卷积层和池化层之后，通常会添加全连接层，将特征图转换为向量，并通过全连接层进行分类、识别或其他任务。

损失函数：用于衡量模型预测值与真实值的差异，优化模型参数的目标函数。

2.2 目标检测

目标检测是计算机视觉领域的重要任务，旨在识别和定位特定对象。目标检测不仅需要识别物体类别，而且还需要确定位置，通常用边界框来表示。目标检测的主要步骤：

目标定位：首先需要定位可能存在目标的位置。一般通过滑动窗口或区域提议来实现。滑动窗口是在图像上移动一个固定大小的窗口，并对每个窗口进行分类；而区域提议方法是通过预先生成一系列可能包含目标的候选区域，再利用分类器对每个候选区域进行识别，这减少了后续的计算量，提高了检测效率。

目标分类：在确定了候选区域或边界框之后，目标检测模型需要对每个边界框中的物体进行分类，即确定物体的类别。这通常通过在每个候选区域上应用图像分类模型来实现，例如卷积神经网络（CNN）。

边界框回归：除了确定物体类别外，目标检测还需要准确地定位物体的位置。这通常通过边界框回归来实现，旨在对候选区域的边界框进行微调，以更准确地匹配物体的实际位置。

后处理：经过目标分类和边界框回归后，我们通常会遇到多个边界框重叠或冗余的情况。为了得到最终精确且简洁的检测结果，需要进行后处理步骤，其中非极大值抑制（NMS）是一种常用的方法。能够显著优化目标检测的效果。

2.3 数据集

本文神经网络的训练采用的数据集为由大连理工大学提出的 RUOD 数据集^[16]。RUOD 数据集是一个独特的水下目标检测数据集，其特色在于涵盖了多种一般水下场景以及多种水下检测挑战。该数据集标记的目标类别相当丰富，包括鱼、潜水员、海星、珊瑚、海龟、海胆、海参、扇贝、鱿鱼和水母等 10 类海洋生物。

除了常规的训练集和测试集之外，RUOD 数据集还特地包含了三个环境挑战的测试集，它们分别是雾效应、色偏和光干扰。这些特殊的测试集设计，使得 RUOD 数据集能够全面评估检测器在各种水下环境条件下的性能。这种全面的评估能力，使得 RUOD 数据集在水下目标检测领域具有极高的实用价值和研究价值。

第3章 基于深度学习的海洋生物检测的设计和实现

本章将详细介绍 YOLOv9 神经网络模型，并针对其在实时性和计算资源消耗方面的挑战，提出使用 MobileNetV3 进行轻量级优化的方案。随后，我们将探讨如何进一步对优化后的模型进行性能调优，以确保在降低模型复杂度的同时，保持甚至提升其检测性能。

3.1 YOLOv9 神经网络模型

YOLOv9^[17]是今年 2 月 21 日由 Chien-Yao Wang 等人共同提出的新一代目标检测系统，是 YOLO 系列中的最新产品。YOLOv9 提出了 PGI（Programmable Gradient Information）思想，即反向传播过程梯度信息丢失的问题需要以被解决。YOLOv9 的网络结构，如图 3-1 所示：

1.Backbone（骨干网络）：

负责从输入图像中提取出关键的特征信息，并将不同层次的特征图进行融合，有效地捕捉图像中的上下文信息。

2.Head（头部）：

负责聚集 Backbone 提取的特征，并通过特定策略细化这些信息，特别注重增强不同尺度的空间和语义信息，以提高检测准确性。以及负责最终的目标检测任务，包括分类和边界框回归。

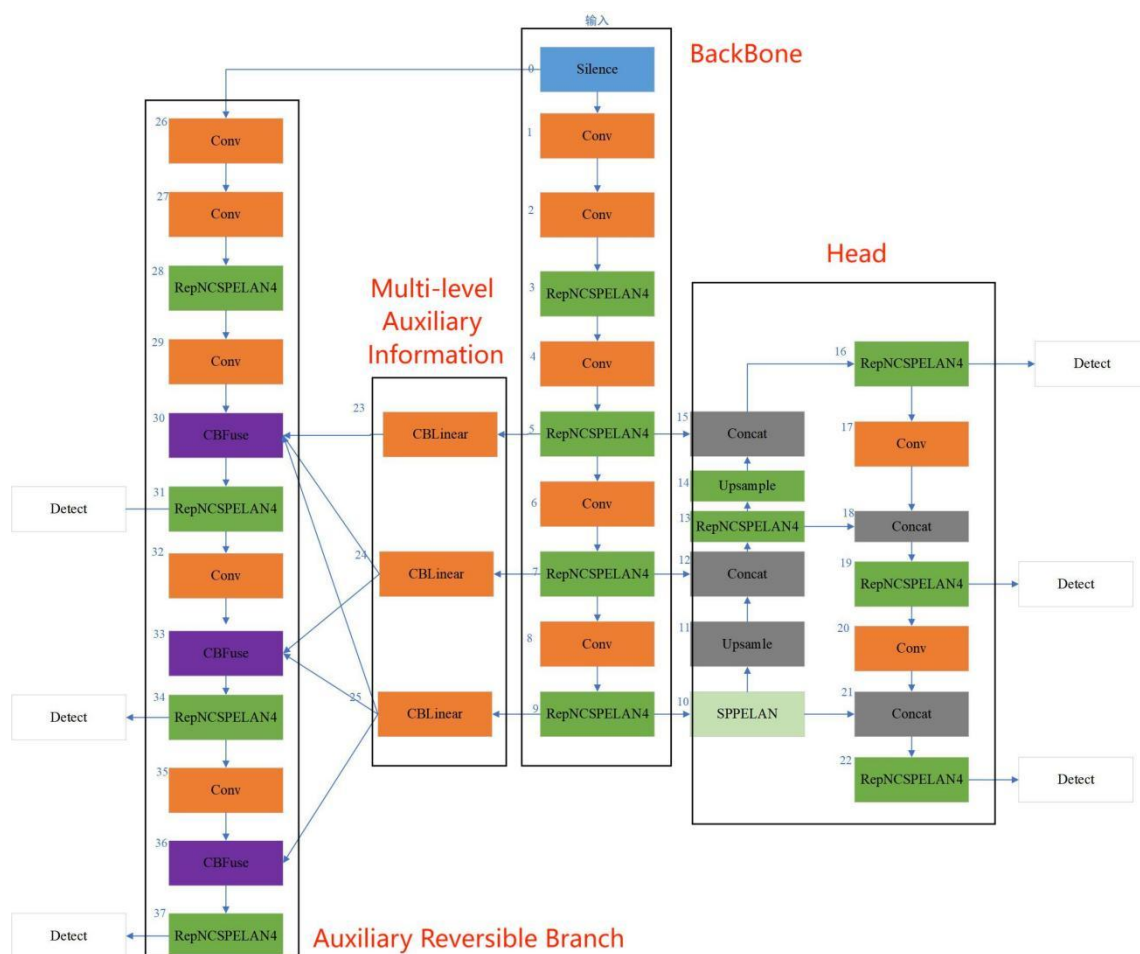
3.辅助可逆分支（Auxiliary Reversible Branch）：

引入可逆结构虽能确保信息的完整性，但这也使 Backbone 参数量增长显著，增加了推理时的计算成本。在训练过程中帮助 backbone 更好地获得丰富的返回梯度信息，使得 backbone 具有更高的表现；而在推理过程中丢弃该分支，使得推理过程并没有增加时间损耗。该模块仅在训练模式使用。

4.多级辅助信息（Multi-level Auxiliary Information）：

引入辅助分支来捕获和整合不同尺度和层次的特征信，旨在提高模型的检测精度和性能。同时它还通过梯度传播的方式影响主分支的学习过程。在训练过程中，辅助分支的梯度信息会反向传播到主分支中，帮助主分支更好地学习到目标物体的特征。这种梯度传播的方式有助于缓解深层网络中梯度消失的问题，提高模型的训练效果。该模块仅在训练模式使用，因为其返回的梯度从辅助可逆分支

中获取。



级、高推理速度和准确度的特点。在目标检测任务中，GELAN 架构能够有效地提取和利用图像中的特征信息，提高目标检测的准确性和效率。

3.2 轻量化改进：MobileNetV3 替换骨架网络

3.2.1 MobileNetV3 网络结构

MobileNetV1^[18]的推出标志着深度学习领域的一次重要革新。传统的卷积神经网络在图像处理任务中虽然表现优异，但往往需要大量的计算资源和内存，限制了其在移动设备和嵌入式系统中的应用。为了解决这个问题，MobileNetV1 创造性地引入了深度可分离卷积（Depthwise Separable Convolution）的概念。随后，MobileNetV2^[19]在 MobileNetV1 的基础上进行了进一步的优化。它引入了倒残差结构（Inverted Residual Structure），这种结构能够更好地利用深度可分离卷积的优势，同时减少信息损失。此外，MobileNetV2 还将结构中的激活函数从 ReLU6 更改为线性激活函数（Linear Activation），以减少非线性变换对模型性能的影响。MobileNetV3 在继承 V1 和 V2 的优点之上，又引入了 SE 模块、h-swish 激活函数等创新，进一步提升了模型的性能和效率。首先，它引入了 SE（Squeeze-and-Excitation）模块，该模块通过学习每个通道的重要性，对通道间的依赖关系进行建模，从而增强模型的表示能力。其次，MobileNetV3 将 swish 激活函数更新为 h-swish 函数，h-swish 函数是 swish 函数的简化版本，它保留了 swish 函数的优点，同时减少了计算量。最后，MobileNetV3 重新设计了耗时层的结构，通过优化网络中的瓶颈层（Bottleneck Layer）和引入新的高效层（Efficient Layers），进一步提高了模型的性能和效率。MobileNetV3 模型结构参数如表 3-1。

表 3-1 MobileNetV3 结构图

Input	Operator	exp size	out	SE	NL	s
$224^2 \times 3$	conv2d, 3×3	-	16	-	HS	2
$112^2 \times 16$	bneck, 3×3	16	16	√	RE	2
$56^2 \times 16$	bneck, 3×3	72	24	-	RE	2
$28^2 \times 24$	bneck, 3×3	88	24	-	RE	1

$28^2 \times 24$	bneck, 5×5	96	40	$\sqrt{\quad}$	HE	2
$14^2 \times 40$	bneck, 5×5	240	40	$\sqrt{\quad}$	HE	1
$14^2 \times 40$	bneck, 5×5	240	40	$\sqrt{\quad}$	HE	1
$14^2 \times 40$	bneck, 5×5	120	48	$\sqrt{\quad}$	HE	1
$14^2 \times 48$	bneck, 5×5	144	48	$\sqrt{\quad}$	HE	1
$14^2 \times 48$	bneck, 5×5	288	96	$\sqrt{\quad}$	HE	2
$7^2 \times 96$	bneck, 5×5	576	96	$\sqrt{\quad}$	HE	1
$7^2 \times 96$	bneck, 5×5	576	96	$\sqrt{\quad}$	HE	1
$7^2 \times 96$	conv2d, 1×1	-	576	$\sqrt{\quad}$	HE	1
$7^2 \times 576$	Pool, 7×7	-	-	-	-	1
$7^2 \times 576$	conv2d, 1×1 , NBN	-	1024	-	HS	1
$1^2 \times 1024$	conv2d, 1×1 NBN	-	k	-	-	1

3.2.2 YOLOv9-MobileNetV3 网络设计

为了降低 YOLOv9 模型的参数数量和计算复杂度，因此在本研究中移除了 MobileNetV3-Small 网络的最后四层并选择保留关键模块来替代 YOLOv9 的骨干网络部分。

Yolov9 的骨干网络输入图片大小为 640×640 ，最后输出图片大小为 20×20 ，因此输入图片需要经过 32 倍下采样。然后头部网络中的某些神经网络层需要与骨干网络中的某些神经网络层进行特征图拼接，其中包括网络第七层与网络第十一层拼接 16 倍下采样特征图 (40×40)，网络第五层和网络第十四层拼接 8 倍下采样特征图 (80×80)。MobileNetV3-Small 网络前 12 层输入 640×640 输出也为 20×20 。满足最终输出要求。其中第四层进行了 8 倍下采样，第九层进行了 16 倍下采样，也满足特征图拼接要求。所以将 yolov9 主干网络用 MobileNetV3-Small 网络前 12 层替换，将原十一层与 MobileNetV3-Small 第九层拼接，原十四层与 MobileNetV3-Small 第四层拼接。并把 MobileNetV3-Small 第四、九、十二层作

为多级辅助信息层。修改后的网络结构如图所示。

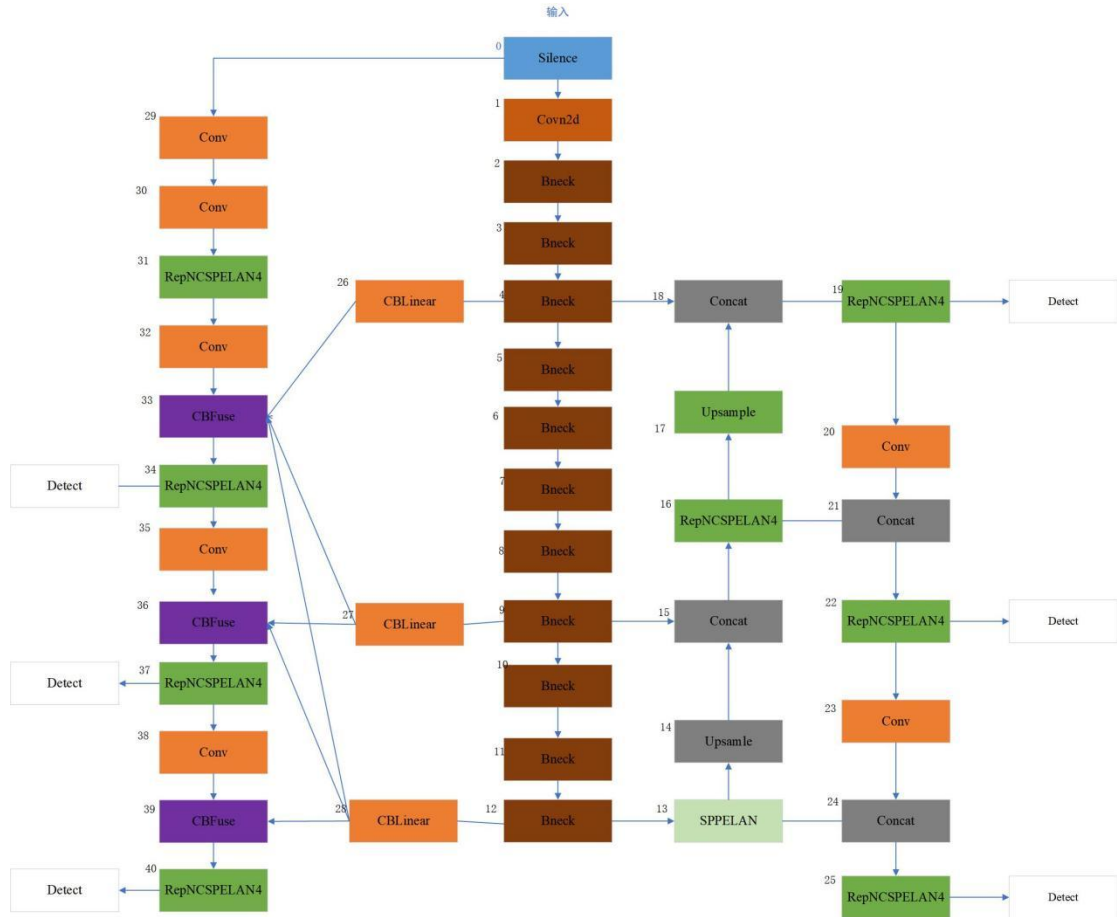


图 3-2 Yolov9-MobileNetV3 结构图

通过将 YOLOv9 的主干网络替换为 MobileNetV3 后,我发现虽然模型的准确度稍微有所下降,但计算量和 GFLOPs (每秒浮点运算次数)都有了显著的提升。这意味着替换后的模型在保持一定精度的同时,能够更快地进行推理,并且所需的计算资源更少。使其更适用于实时场景和资源受限环境。

3.3 MobileNetV3 优化：注意机制替换

由于 MobileNetV3 中使用的 SE 模块只考虑了编码通道之间的信息来衡量每个通道的重要性^[21],却忽略了对捕捉识别对象结构至关重要的位置信息。因此,为了提高模型识别率,增强模型对海洋生物位置信息的捕捉,必须考虑坐标信息。本文通过引入 CA 来改进 MobileNetV3 模型,将 MobileNetV3 结构中的 SE 模块替换为 CA 模块,从而实现对 MobileNetV3 模型的优化。

CA 注意力机制不仅可以捕捉到跨通道信息,还可以捕捉到位置敏感信息^[22],对关键的像素坐标位置给予较大的权重,同时 CA 模块的计算开销也很小,符合

本文的要求。CA 注意力机制不同于传统二维全局池化，它将通道注意力拆分为两个一维编码过程，整合垂直和水平方向的空间信息到注意图中。这种方法能捕获长距离依赖关系，同时保留精确位置信息。通过乘法加权特征图，使模型对感兴趣目标更加关注。

CA 的计算过程如图 3-3 所示。假设输入为 $C \times H \times W$ 的特征图，其中 C 为通道数， H 为特征图高度， W 为特征图宽度。CA 将二维全局池化操作转换为一对不同方向上的一维全局池化操作，并将长宽方向上的特征信息进行拼接和 1×1 卷积降维，得到一个 $C/r \times 1 \times (W+H)$ 的中间特征图，其中 r 为用于缩减通道数的缩放因子。随后再将中间特征图分解为 2 个方向上的特征图，再次通过 1×1 卷积升回到原来的维度并通过 Sigmoid 激活函数得到长宽方向上最终的特征图。最后，这些特征图经过元素相乘的操作，与两个最终的方向特征图相结合，生成最终的输出特征图。

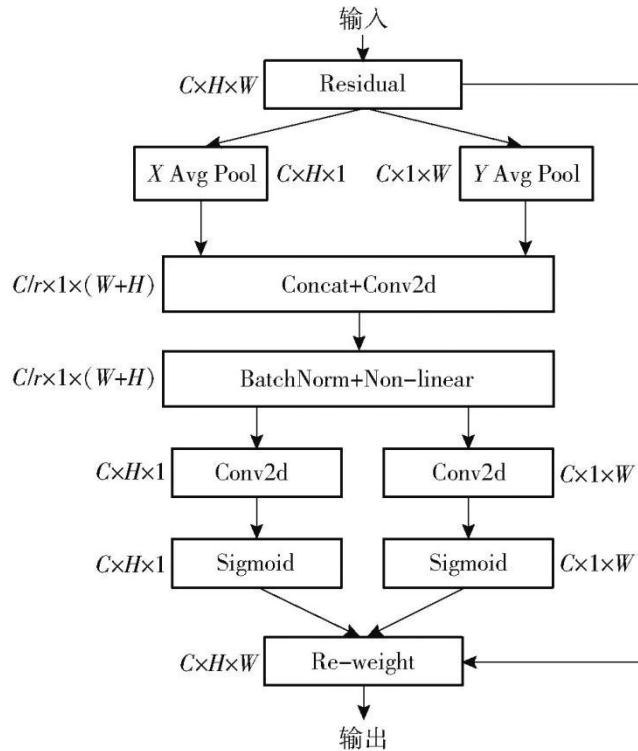


图 3-3 CA 注意力机制的计算过程

3.4 添加双端注意机制 (SE+CA)

本文在 YOLOv9 的 head 端最后一层添加 SE 和 CA 的双端注意力模块，结构见图 3-4，原因如下:(1)提高模型性能和精度：SE (Squeeze-and-Excitation) 和

CA（Channel Attention）注意力模块在深度学习模型中扮演着重要角色。SE 通过学习通道之间的依赖关系，自适应地重新校准通道的特征响应，从而提高模型的表示能力。而 CA 模块则可以同时考虑通道维度和空间维度上的注意力，使得模型能够关注到图像中更关键的区域。这两种注意力机制的结合可以进一步提升模型的性能和精度。(2)应对不同场景：SE 适用于通道数较多的场景，而 CA 则适用于需要考虑空间维度上的注意力的场景。在目标检测任务中，输入图像可能包含大量的通道信息，并且目标的位置和大小也可能变化较大。因此，SE 和 CA 的双端注意力模块可以更好地应对这些挑战，提高模型在不同场景下的鲁棒性。(3)融合多种注意力机制的优势：SE 和 CA 是两种不同的注意力机制，它们各自具有独特的优势。通过将它们结合在一起，可以充分利用它们各自的优势，提高模型的性能。

总的来说，YOLOv9 在 head 端最后一层添加 SE 和 CA 的双端注意力模块是为了进一步提高模型的性能和精度，应对不同场景下的挑战，并融合多种注意力机制的优势。在 YOLOv9 网络中，由于处于骨干网络最后一层，可以起到了重要的连接的作用，由于之后的 neck 端自底向上，自上而下的特殊构造，不同尺度的特征在这里进行充分融合，为之后预测的奠定基础，所以 SE 和 CA 的双端注意力模块放在骨干网络最后一层的结构极大影响了算法性能。最终的 Yolov9 网络结构如图 3-5 所示。




图 3-4 DoubleAttention 结构图

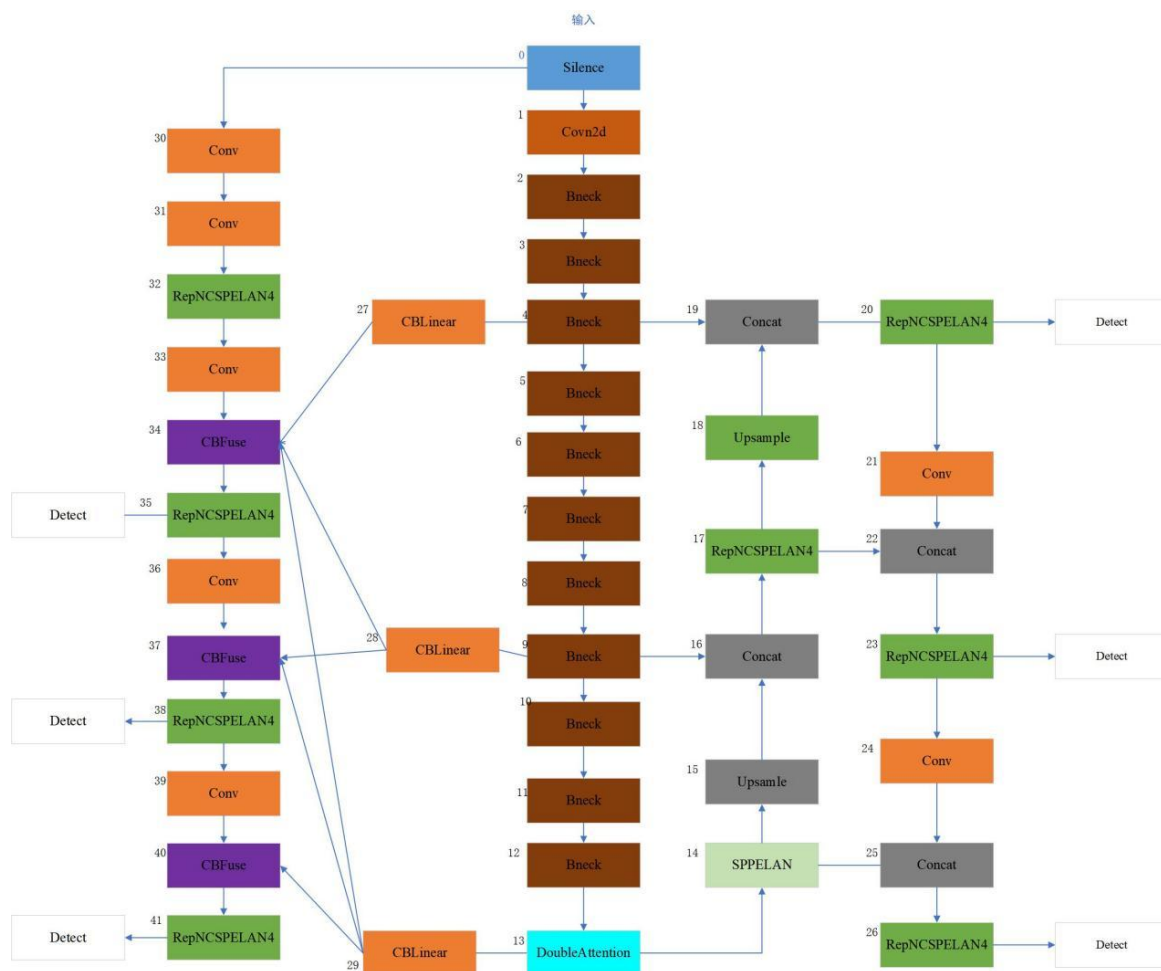


图 3-5 Yolov9-CAMobileNetV3D 结构图

第4章 基于深度学习的海洋生物检测的实验结果

4.1 评价指标

目标检测分类中，常见的评价指标有 mAP、召回率以及检测速度等等。在海洋生物检测中，算法产生的边界框被称为样本，若边界框中含有海洋生物则为正样本，若不含海洋生物则为负样本。为评估本文方法的有效性，采用以下三个度量指标：

1.精确率(Precision):在所有识别为正的样本中，真的正样本所占的比例，公式表达如下：

$$\text{Precision} = \frac{TP}{TP + FP} \quad (4-1)$$

2.均值平均精度 mAP(Mean Average Precision):衡量整个目标检测算法的检测精度，公式表达如下：

$$\text{mAP} = \frac{1}{Q_R} \sum_{q \in Q_R} AP(q) \quad (4-2)$$

3.召回率(Recall):对于所有的正样本，被正确识别的比例，公式表达如下：

$$\text{Recall} = \frac{TP}{TP + FN} \quad (4-3)$$

其中，TP(TruePositives)表示正样本被正确识别为正样本的数量；

FP(FalsePositives)表示负样本被错误识别为正样本的数量；

FN(FalseNegatives)表示正样本被错误识别为负样本的数量；

TN(TrueNegative)表示负样本被正确识别为负样本的数量；

QR 为类别数量，

4.2 模型优化前后的结果对比

4.2.1 轻量化优化

表 4-1 YOLOv9 轻量化实验结果

Model	Parameters	Precision	Recall	mAP
YOLOv9	60818012	0.85487	0.80325	0.86793
YOLOv9-MobileNetV3	47974474	0.84024	0.76436	0.83474

结果如表 4-1 所示，Yolov9 在经过替换主干网络为 MobileV3 后参数量下降了 12843538，大约 21.1%；与此同时，模型准确度只下降约 1.4%，召回率下降约 3.9%，mAP 下降约 3.3%。由此可见，Yolov9-MobileNetV3 模型参数量大幅减少的同时，模型性能却只有略微下降。MobileV3 的引入显示出其有效性。在保持卓越性能的同时，显著减少了参数量，提升了计算效率，使得模型更加轻便，易于在各种设备上部署。

4.2.2 性能优化

表 4-2 Yolov9-MobileNetV3 优化实验结果

Model	Precision	Recall	mAP
Yolov9-MobileNetV3	0.84024	0.76436	0.83474
Yolov9-CAMobileNetV3	0.84764	0.77386	0.84006
Yolov9-CAMobileNetV3D	0.85012	0.7833	0.85392

结果如上表 4-2 所示，在替换 MobileNetV3 中 SE 注意力机制为 CA 注意力机制后，精度提升至 0.84764，比原模型高出约 0.84%；召回率提升至 0.77386，比原模型高出约 1.24%；mAP 提升至 0.84006，比原模型高出约 0.63%。在此基础上，再加入双端注意力机制后，精度进一步提升至 0.85012，再次高出约 0.29%；召回率进一步提升至 0.7833，高出约 1.23%；mAP 也进一步提升至 0.85392，高出约 1.39%。综上所述，CA 模块的引入以及双端注意力机制的加入，都对模型的目标检测性能产生了积极的影响，从而提高模型的检测能力。

4.2.3 优化后训练数据分析

混淆矩阵（Confusion Matrix）是评估分类模型性能的一种常用工具，特别适用于多分类问题。它将模型的预测结果与真实标签进行比较，展示了模型在每个类别上的分类情况。混淆矩阵中的行代表了真实标签，而列代表了模型的预测结果。优化后模型训练混淆矩阵见图 4-1。由图可知，训练数据集一共有十个类别，分别为 holothurian、echinus、scallops、starfish、fish、corals、diver、cuttlefish、turtle、jellyfish 以及一个背景类别 background。主对角线上的值表示模型正确分类的比率，其中 diver、cuttlefish、turtle 三类正确识别率最高，都高过了 0.9。非主对角线上的值表示模型将一个类别误分类为另一个类别的比率，我们可以看出

错误分类主要是被识别为背景，类与类之间的错误分类较少，有也大约为 0.01。
由此可见优化后模型混淆类别的可能性较低，主要还是将目标识别为了背景。




图 4-1 训练混淆矩阵

图 4-3 精度-置信度曲线图展示了多个分类器在不同置信度水平下的预测精度。从图中可以看出，随着置信度的增加，大多数类别的预测精度也随之提高，这意味着在较高的置信度下，分类器更有可能做出准确的预测。因为增加阈值可以减少误报率，提高模型的预测准确性。然而，这可能会导致召回率下降，因为模型会更加保守，更多地选择那些最有把握的正样本。特别地，当在置信度为 0.986 时，所有类别的平均预测精度达到了 1.00，这表明在这个置信度水平下，分类器对所有类别的预测都极为准确。




图 4-2 精度-置信度曲线图

图 4-3 展示出迭代次数与准确度关系，随着迭代次数的增加，模型逐渐学习到数据的特征，并在训练数据上表现得越来越好，精确度逐渐提高。最终达到了大约 0.85。




图 4-3 迭代次数-准确度图

最后的模型预测出的标签图片如图 4-4 所示。展示出了 16 张模型预测的展示结果图。



图 4-4 模型预测出的标签图片

4.3 与其他目标检测模型性能对比

4.3.1 YOLOv8

YOLOv8^[23]是 YOLO 系列中一款高效、创新、易用且全面的目标检测算法，

适用于各种应用场景。YOLOv8 继续沿用了 YOLO 系列的核心思想，即将图像划分为网格，并在每个网格单元中预测物体的边界框和类别。它通过深度学习和卷积神经网络来实现这一目的，采用了一种端到端的目标检测系统。YOLOv8 在保持实时检测特性的同时，借助更精细的网络架构设计，以及先进的训练策略和技术，显著提升了目标检测的精确度。它引入了改进的多尺度预测技术和自适应锚框优化，能够更准确地预测不同大小对象的位置和大小。此外，YOLOv8 还使用了更先进的特征提取网络，有助于从图像中提取出更丰富、更有区分度的特征。Yolov8 网络结构图见图 4-4。

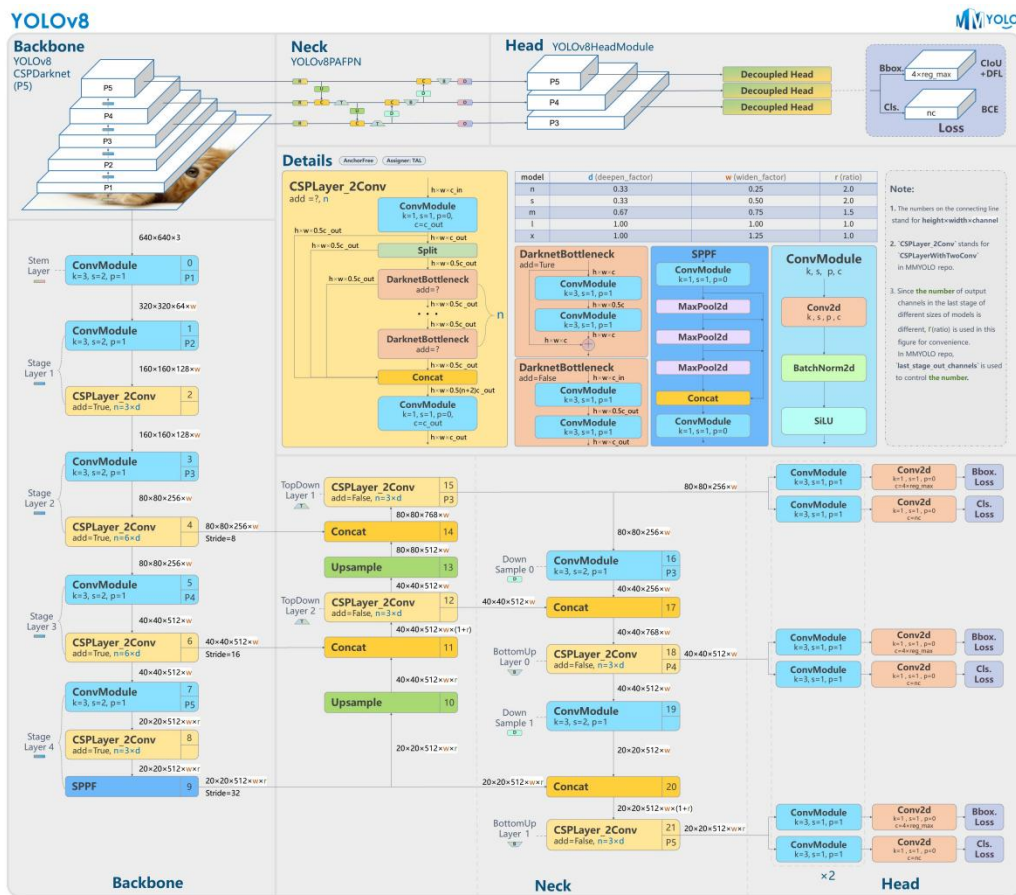


图 4-4 Yolov8 网络结构图

4.3.2 SSD

SSD^[24]是一种单次检测的物体检测算法，其核心思想是将图像分为多个区域，并在每个区域内进行物体检测。它使用多个卷积层来提取图像的特征，并在每个特征层上进行物体检测。SSD 的主要优势在于其简单性和速度，可以在实时应用中得到广泛应用。SSD 的主要创新点包括多尺度特征融合和默认边界框机制。多尺度特征融合使得 SSD 能够更好地捕捉不同大小目标的信息，而默认边界框

机制则通过回归预测这些默认框的位置偏移和类别概率，从而得到最终的检测结果。此外，SSD 还采用了一种高效的非极大值抑制算法，进一步提高了检测速度。网络结构如图 4-2 所示。




图 4-5 SSD 网络结构

4.3.3 Faster R-CNN

Faster R-CNN^[25]是一个两阶段的目标检测算法，它引入了建议框（Region Proposal）的概念。Faster R-CNN 将特征抽取、目标识别、候选框生成和分类预测集中在同一个网络中，使得模型的训练速度和检测精度相较于之前的 Fast R-CNN 有较大提高。Faster R-CNN 主要包括三个部分：前置特征提取网络（也称主干网络）、候选区域建议网络（Region Proposal Network, RPN）以及基于感兴趣区域池化（RoI Pooling）和全连接层的目标分类与位置回归网络。Faster R-CNN 在许多数据集上都展现出优异的性能，具备了良好的迁移性能。通过简单地调整数据集中的目标类别，就能够轻松地改变测试模型的应用场景。其优秀的性能和灵活的迁移能力，使得 Faster R-CNN 成为目标检测领域的研究热点和实践首选。这种特性为各种不同领域的应用提供了更多可能性，并且促进了目标检测技术的进一步发展和应用推广。

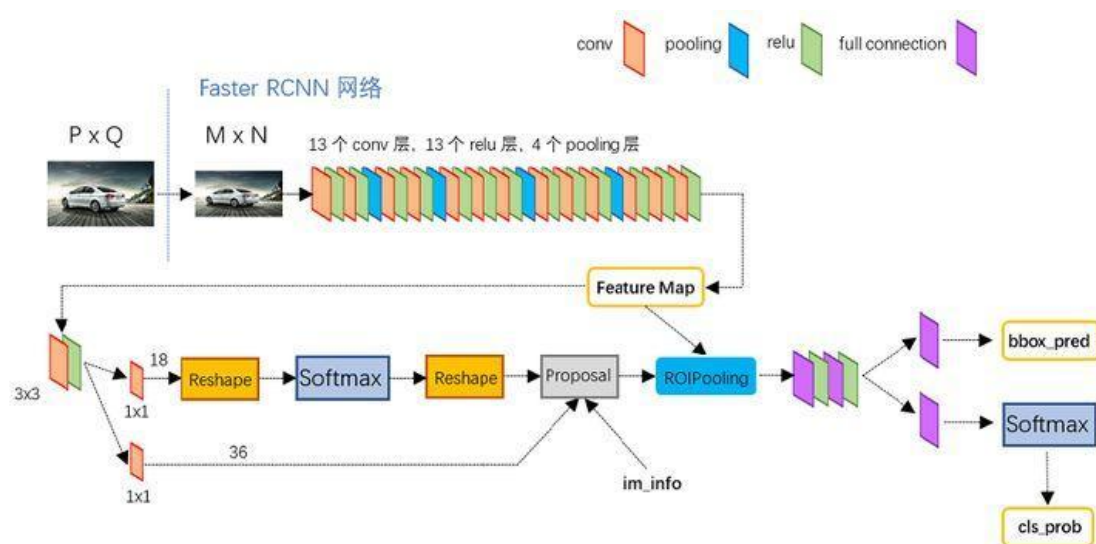


图 4-6 Faster R-CNN 网络结构

4.3.4 实验结果

表 4-3 与其他目标检测模型性能对比实验结果图

Model	Precision	Recall	mAP
Yolov8	0.832	0.74908	0.8208
SSD	-	-	0.5954
Faster R-CNN	-	-	0.8175
Yolov9-CAMobileNetV3D	0.85012	0.7833	0.85392

实验结果如表 4-3 所示, 优化后的 Yolov9-MobileNetV3 准确度高出 Yolov8 大约 2%, 召回率高出大约 3%。而在 mAP 方面, 我们的模型高出 Yolov8 大约 3%, 高出 SSD 大约 25%, 高出 Faster R-CNN 大约 4%。我们的模型无论是在精度、召回率还是 mAP 上都表现更好, 比其他模型具有更高的综合性能。

4.4 在其他数据集性能表现

4.4.1 Aquarium

数据集 Aquarium 是一个针对海生物的开源数据集，由 Roboflow 提供。这个

数据集包含了 640 张图片，展示了 7 种不同的海洋生物。此外，该数据集还提供了经过旋转和翻转等增强处理后的版本，增强后的图片总数达到了 4670 张。这些增强操作有助于提升模型在水下目标检测任务中的泛化能力。

4.4.2 RUIE

RUIE^[26]全称 Realworld-Underwater-Image-Enhancement-RUIE-Benchmark，是一个大连理工大学的自制数据集，共计 300 张图片，是一个专门为多角度算法评估而设置的大型水下真实图像数据库。

4.4.3 实验结果

表 4-3 与其他目标检测模型性能对比实验结果图

Dataset	Precision	Recall	mAP
Aquarium	0.83331	0.62359	0.71867
RUIE	0.84204	0.36679	0.44128

实验结果如表 4-3 所示，相较于数据集 RUOD，我们模型在 Aquarium 和 RUIE 上表现不是很好，我分析原因大概是 Aquarium 和 RUIE 数据集数据太少导致。其中 RUIE 召回率和 mAP 都比较低大概也是因为这个原因，但是我们模型在两个数据集上的准确性还是很不错，模型泛化能力还是不错的。

第 5 章 海洋生物检测系统的搭建

将已经训练好的模型应用于实际的海洋图像检测任务，实现部署至 Web 平台。采用前后端分离开发，这样的架构将允许系统更高效地处理海洋图像数据，同时提供用户友好的界面和交互性。

5.1 框架选择

前端将采用 Vue 框架。Vue 是一个前端 JavaScript 框架。它具有简单易学的特点，结合了反应性数据绑定和组件化构建的优势，能有效提高网页开发的效率，缩短开发周期。

后端采用 Flask 框架，Flask 设计简单且易于学习，是一个轻量级 WEB 开发框架。同时 Flask 是用 Python 实现的 Web 框架之一，这将有利于更好更方便的调用已经训练好的模型，同时也允许系统更高效地处理海洋图像数据，

5.2 功能模块设计

海洋生物检测系统主要包括以下两个功能：1.用户的登录注册；2.海洋生物检测。本系统的功能模块如图 5-1 所示。用户登录模块负责用户的登录注册请求，确保系统安全和用户身份验证。海洋生物检测模块则负责处理图像或视频数据，通过算法识别和分析海洋生物，提供检测服务。这些功能模块相互配合，构成了完整的海洋生物检测系统。

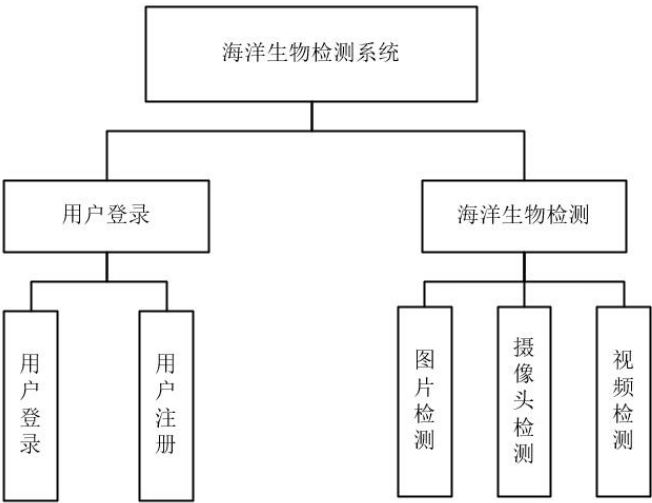


图 5-1 系统功能模块

5.3 业务流程设计

进入系统后，判断用户是否已拥有账号，若已有账号，则进行登录流程，否则进行注册。登录成功后，用户将被重定向至系统首页，并可以选择进行海洋生物检测，包括图片、视频或使用摄像头进行实时检测。具体流程设计见图 5-2 所示。

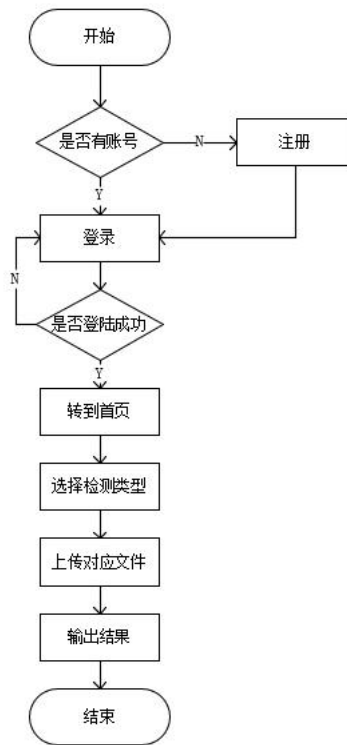


图 5-2 系统业务流程设计

5.4 模块展示

5.3.1 登录模块

用户输入账号和密码后，点击登录按钮。账号密码将以表单的形式发送到后端。后端对账号密码进行验证，如果验证通过，则将转到系统首页；反之，则返回错误信息，指出账号密码错误的具体原因，如账号不存在或密码不正确。这样的流程确保了系统安全性和用户信息的保密性。

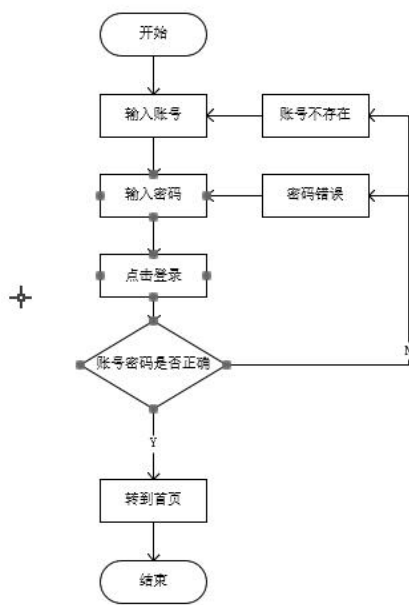


图 5-3 登录流程

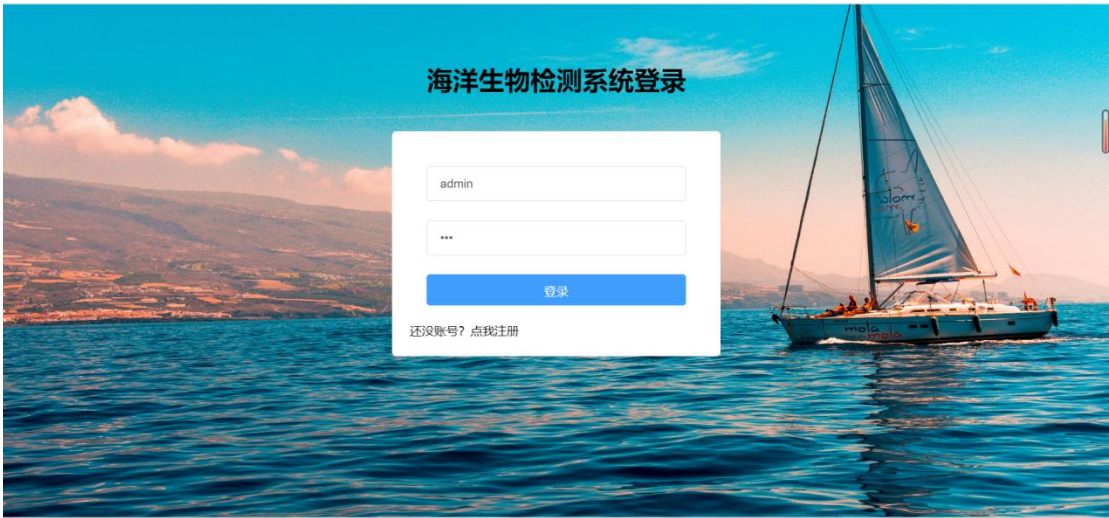


图 5-4 登录界面

5.3.2 注册模块

用户输入邮箱地址后，点击发送验证码，后台会发送生成的四位验证码到用户邮箱，然后用户输入验证码、用户名、密码和确认密码。若密码和确认密码不一致，用户需重新输入。这种设计确保了账户信息的准确性和安全性，提高了用户体验。用户点击注册。

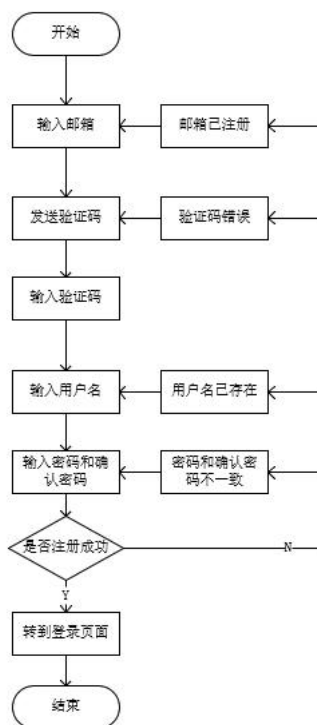


图 5-5 注册流程

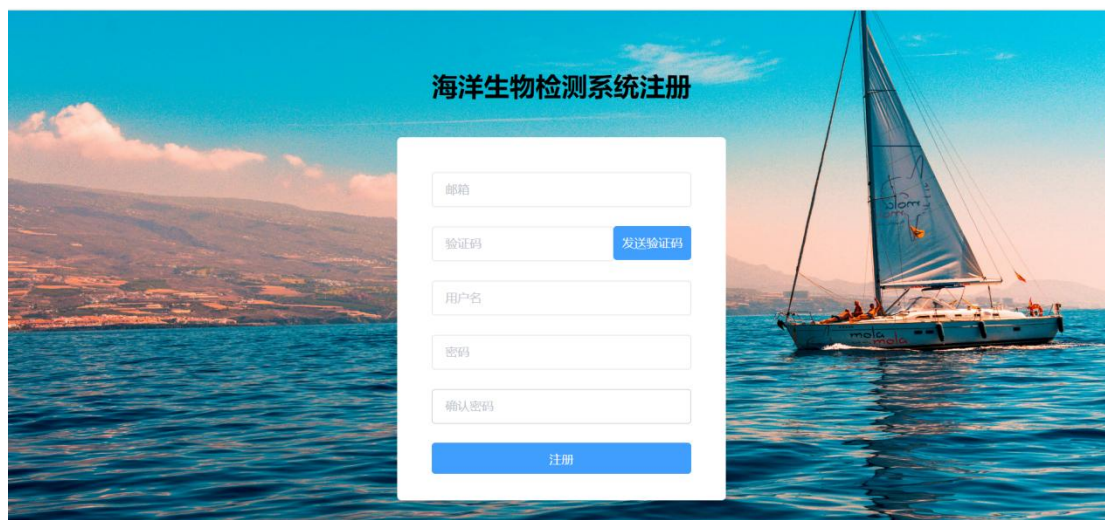


图 5-6 注册界面

5.3.3 图片检测模块

用户选择上传图片，系统回返检测结果图片，返回检测结果信息，如检测类别，置信度，位置等。




图 5-7 图片检测流程




图 5-8 图片检测界面

5.3.4 视频检测模块

用户上传视频，后端逐帧检测，然后以视频流返回检测结果。



图 5-9 视频检测流程

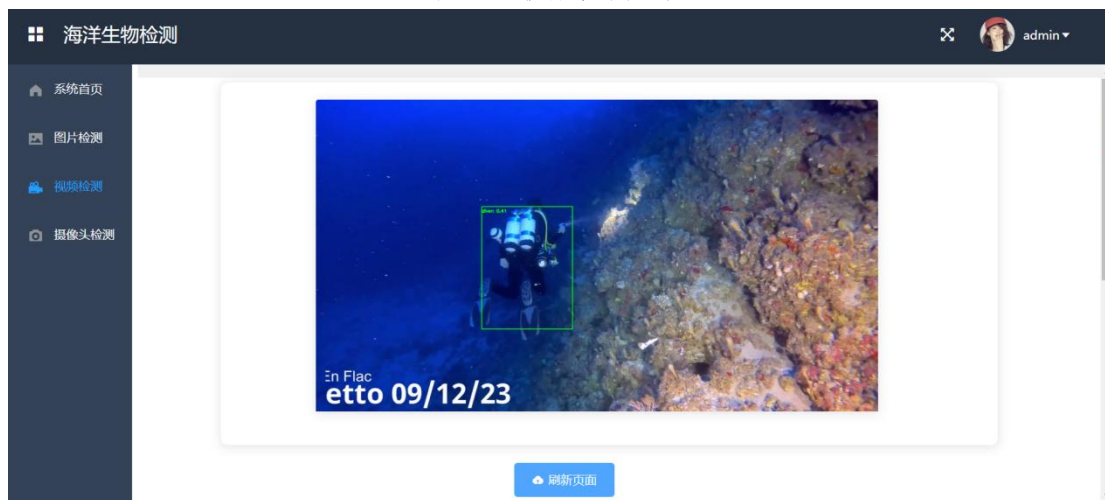


图 5-10 视频检测界面

5.3.5 摄像头检测模块

用户打开摄像头，后端逐帧检测，然后以视频流返回检测结果。




图 5-11 摄像头检测流程

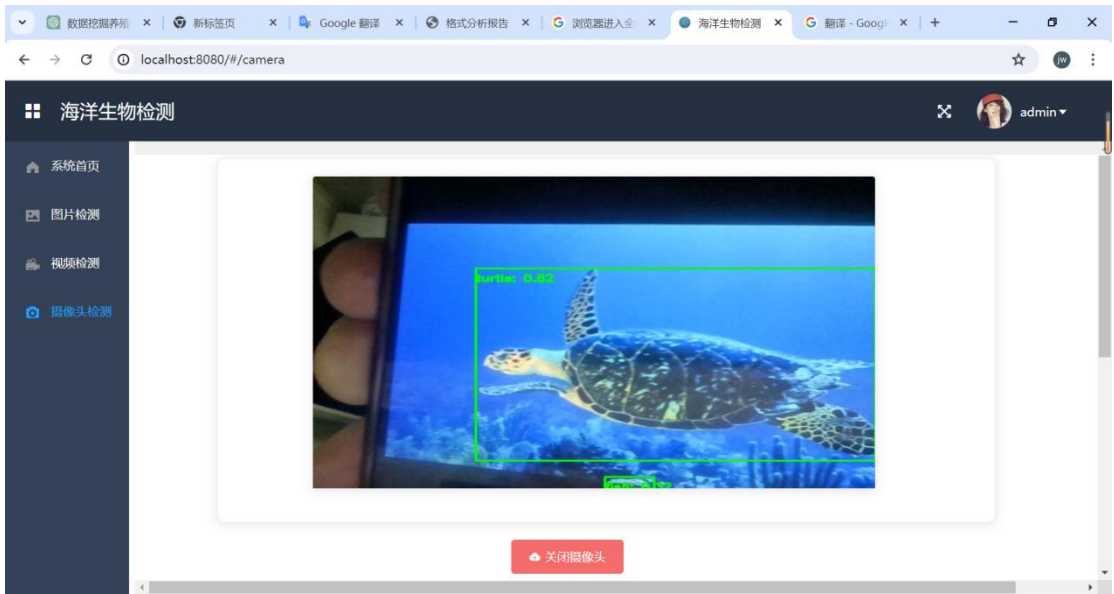


图 5-12 摄像头检测界面

第 6 章 总结与展望

6.1 总结

海洋生物是海洋生态系统中的重要组成部分，对于维持海洋生态平衡和生物多样性具有重要意义。基于深度学习的海洋生物检测研究也就具有重要的科学意义和应用价值，有助于更好地理解 and 保护海洋生态环境，推动海洋资源的可持续利用和海洋科学的发展。本文提出了一个优化的 Yolov9-mobileNetV3 模型进行海洋生物检测，并将训练好的模型部署到了 web 平台，应用于实际的海洋图像检测任务。

本文的总结工作如下：

- (1) 针对 Yolov9 复杂度高、参数量大、应用部署环境要求高等问题，本文研究了将 MobileNetV3 替换 Yolov9 主干网络从而实现网络轻量化，测试结果大幅度降低参数量，但网络性能有所降低。
- (2) 再针对 Yolov9-MobileNetV3 网络性能下降问题，提出了替换 MobileNetV3 中 SE 为 CA 以及加入一层双端注意力机制的优化方案，提升了 Yolov9-MobileNetV3 网络性能。
- (3) 对优化后的 Yolov9-MobileNetV3 网络进行对比实验以及将它应用于其他数据集，充分体现出它的优越性能以及泛化能力。
- (4) 本文利用 VUE 和 Flask，设计了一个海洋生物检测网站，具有对图片，视频和摄像头进行海洋生物检测功能。

6.2 展望

本文开展了基于深度学习的海洋生物检测的研究与探索，虽然取得了一定的进展，但仍有几个问题需要进一步研究与完善：

- (1) 本文研究的数据集中，海洋生物类别的数量相对较少，且仍有许多海洋生物类别未包含在内。为了提升数据丰富度，需要进一步扩充数据集。这包括添加更多种类的海洋生物，例如各种鱼类、海洋植物、软体动物等。此外，还可以考虑涵盖各种典型的海洋生物场景，比如珊瑚礁、海草床等。

通过扩充数据集，可以更全面地反映真实海洋环境中的生物多样性，从而提高模型的泛化能力和检测准确率。

- （2）虽然本文提出改进模型在性能和模型参数方面有所提升，但模型检测精度难以得到较大提升，分析原因是水下环境对目标检测的影响导致海洋生物特征难以提取，小目标生物难以检测，未来工作将考虑选用性能更优的算法对水下生物进行检测，使检测精度、检测速度以及模型尺寸大小能够满足实际应用需求是本文下一步研究的重点。
- （3）本文设计了海洋生物检测系统，将训练好的模型部署到 web 平台，未来将尝试将性能优异的海洋生物检测模型部署到安卓平台或者嵌入式设备中，满足实际生产生活所需的抓取任务、监测任务，使检测算法由理论转为应用。

随着对海洋生物研究需求的不断提高，对海洋生物检测技术的精度和实时性要求也将越来越高。未来的海洋生物检测技术将更加依赖自动化和智能化系统。这些系统能够自主运行，实时收集和分析数据，无需人工干预即可做出准确的判断和预测。例如，通过人工智能和机器学习技术，我们可以开发出能够自动识别和分类海洋生物种类、数量和行为的系统。同时，未来的海洋生物检测技术将更加注重生态化和环保化。在检测过程中，我们将尽量减少对海洋环境的影响和污染。同时，我们还将加强对海洋生态系统的监测，了解海洋生物的分布和数量变化情况，为生态保护提供科学依据。

参考文献

- [1] 汪丽. 中国海洋资源[M]. 吉林: 吉林出版社, 2010.
- [2] Liu Y, An D, Ren Y, et al. DP-FishNet: Dual-path Pyramid Vision Transformer-based underwater fish detection network[J]. Expert Systems with Applications, 2024, 238: 122018.
- [3] Yu G, Cai R, Su J, et al. U-YOLOv7: A network for underwater organism detection[J]. Ecological Informatics, 2023, 75: 102108.
- [4] 白欣莹. 基于深度学习的海洋生物目标检测系统的研究与实现[D]. 辽宁大学, 2023. DOI:10.27209/d.cnki.glniu.2023.001769.
- [5] Liu Y, Wang S. A quantitative detection algorithm based on improved faster R-CNN for marine benthos[J]. Ecological Informatics, 2021, 61: 101228.
- [6] Hu X, Liu Y, Zhao Z, et al. Real-time detection of uneaten feed pellets in underwater images for aquaculture using an improved YOLO-V4 network[J]. Computers and Electronics in Agriculture, 2021, 185(8): 106135.
- [7] Zhang M, Xu S, Song W, et al. Lightweight Underwater Object Detection Based on YOLO v4 and Multi-Scale Attentional Feature Fusion[J]. Remote Sensing, 2021, 13(22): 4706.
- [8] Li X, Yu H, Chen H. Multi-scale aggregation feature pyramid with corneriness for underwater object detection[J]. Visual computer, 2023.
- [9] 宛鹤, 张金艳, 屈娟萍等. 基于改进 MobileNet V3 的矿物智能识别模型[J/OL]. 金属矿山: 1-12[2024-01-06]. <http://kns.cnki.net/kcms/detail/34.1055.TD.20231220.1749.003.html>.
- [10] 李健, 王晨, 马振宇等. MobileNet-CAL: 基于迁移学习和注意力机制的番茄病虫害分类方法[J/OL]. 吉林大学学报(工学版): 1-9[2024-01-06]. <https://doi.org/10.13229/j.cnki.jdxbgxb.20230828>.
- [11] 钱铖, 沈凯文, 王淳等. 一种基于 MobileNet 模型的医疗废弃物收集小车[J]. 常熟理工学院学报, 2023, 37(05): 51-56+66. DOI:10.16101/j.cnki.cn32-1749/z.2023.05.016.
- [12] 苏童. 基于改进 YOLO-MobileNet 的近红外图像特征驾驶员人脸检测[J]. 兰州工业学院学报, 2023, 30(05): 90-93+106.
- [13] Xu S, Zhang M, Song W, et al. A systematic review and analysis of deep learning-based underwater object detection[J]. Neurocomputing, 2023.
- [14] Liu Y, An D, Ren Y, et al. DP-FishNet: Dual-path Pyramid Vision Transformer-based

- underwater fish detection network[J]. *Expert Systems with Applications*, 2024, 238: 122018.
- [15] Yu G, Cai R, Su J, et al. U-YOLOv7: A network for underwater organism detection[J]. *Ecological Informatics*, 2023, 75: 102108.
- [16] Fu C, Liu R, Fan X, et al. Rethinking general underwater object detection: Datasets, challenges, and solutions[J]. *Neurocomputing*, 2023, 517: 243-256.
- [17] Wang, C., Yeh, I., & Liao, H. (2024). YOLOv9: Learning What You Want to Learn Using Programmable Gradient Information. *ArXiv*, abs/2402.13616.
- [18] Howard, A.G., Zhu, M., Chen, B., Kalenichenko, D., Wang, W., Weyand, T., Andreetto, M., & Adam, H. (2017). MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications. *ArXiv*, abs/1704.04861.
- [19] M.Sandler, A. Howard, M. Zhu, A. Zhmoginov and L. -C. Chen, "MobileNetV2: Inverted Residuals and Linear Bottlenecks," 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition, Salt Lake City, UT, USA, 2018, pp. 4510-4520, doi: 10.1109/CVPR.2018.00474.
- [20] Howard, A.G., Sandler, M., Chu, G., Chen, L., Chen, B., Tan, M., Wang, W., Zhu, Y., Pang, R., Vasudevan, V., Le, Q.V., & Adam, H. (2019). Searching for MobileNetV3. 2019 IEEE/CVF International Conference on Computer Vision (ICCV), 1314-1324.
- [21] HU J, SHEN L, SUN G. Squeeze-and-excitation networks[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 7132-7141.
- [22] HOU Q, ZHOU D, FENG J. Coordinate attention for efficient mobile network design[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021: 13713-13722.
- [23] Reis, Dillon et al. "Real-Time Flying Object Detection with YOLOv8." *ArXiv* abs/2305.09972 (2023): n. pag.
- [24] Liu, W. et al. "SSD: Single Shot MultiBox Detector." *European Conference on Computer Vision* (2015).
- [25] Ren, Shaoqing et al. "Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks." *IEEE Transactions on Pattern Analysis and Machine Intelligence* 39 (2015): 1137-1149.
- [26] Liu, Risheng et al. "Real-World Underwater Enhancement: Challenges, Benchmarks, and

Solutions Under Natural Light.” IEEE Transactions on Circuits and Systems for Video Technology 30 (2019): 4861-4875.

致 谢

在本篇毕业论文即将完成之际，我要对在研究过程中给予我关心、支持和帮助的人们表示衷心的感谢。

首先，我要由衷感谢我的导师周志宇教授。感谢您在整个研究过程中给予我的悉心指导和无私支持。您的学识渊博、严谨治学的态度和勤奋工作的精神都深深地感染着我，让我受益匪浅。您的言传身教将成为我终身受益的财富。

同时，我要感谢与我一起生活和学习的同学们，你们在学习和生活中对我的热情帮助让我感到十分温暖和感激。在过去的日子里，你们为我提供了良好的学习氛围和合作机会，让我能够不断进步和成长。

特别要感谢我的家人，感谢父母对我的关心和支持，让我能够顺利完成学业。没有你们的支持和理解，我将无法度过研究生活中的各种挑战和困难。

再次感谢每一位给予我帮助和支持的人，是你们的陪伴和鼓励让我顺利完成了这篇毕业论文。愿我们共同的努力和收获都能为未来的道路增添光彩。

谨以此文献给所有关心和支持过我的人，感恩有你们！

罗吉伟

2024 年 5 月 11 日